

EDC DataBox v0.3 (2026.05.15. verzió)

Az EDC Debrecen Nonprofit Kft. számára készített "Adatelemzés és vizualizáció a magyar vállalkozások székhely és telephelyadatairól" c. projektfeladat részeként csapatunk önként vállalta, hogy az adattisztításhoz (adatátalakításhoz) szükséges parancssoros programkódot a későbbi újrafelhasználás és a könnyebb használat érdekében grafikus felülettel egészíti ki.



E célból csapatunk az EDC DataBox szoftvert elkészítette, mely fő funkciójaként a magyarországi vállalatok székhely- és telephelyadatait felhasználva egy, a csapatunk által készített Power BI kimutatás alapjául szolgáló adatfájlt exportál.

Telepítés:


1) A program a Python szoftverkörnyezetben fut, ezért szükséges annak telepítése (ha még nincs telepítve):

1. Látogass el a Python letöltések oldalára:
<https://www.python.org/downloads/windows/>
2. Válaszd ki a legfrissebb kiadást (*Latest Python 3 Release - Python 3.xx.x*)
3. Az oldal alján válaszd a következőt: *Windows installer (64-bit)*
4. Indítsd el a telepítőfájlt
5. Jelöld be alul az alábbi két paramétert:
 - a. *Use admin privileges when installing py.exe*
 - b. *Add python.exe to PATH*
6. Kattints az *Install Now* feliratra



2) Látogass el a következő linkre: <https://github.com/polini46corvinus/EDC-DataBox>

3) Kattints a zöld <> *Code* gombra, majd a *Download ZIP* feliratra:



3) Csomagold ki az “EDC-DataBox-main.zip” fájlt tetszőleges helyre.

4) A futtatandó alkalmazás alapértelmezés szerint nincs társítva a Python futtatókörnyezethez (“pythonw.exe”), ezért ezt manuálisan kell megtenni.


4.1) Kattints kétszer a “EDC DataBox.pyw” fájlra (vagy jobb egérgomb, **Társítás**)

4.2) Válaszd ki a Python-t (ha több is van, érdemes a fehér “pythonw.exe”-t választani), majd kattints a *Mindig* gombra, vagy pedig jelöld be, hogy *Mindig ez az alkalmazás nyissa meg ezt a fájl típust (.pyw)*.

A “pythonw.exe” jellemzően ezen az útvonalon található (verziószám különbözhet):

C:\Users\%userprofile%\AppData\Local\Programs\Python\Python314


A beállítás után így kell kinéznie:



5) Az alkalmazás a Python beépített csomagjain kívül a következő külső modulokat (bővíítőcsomagokat) is használja:

- Numpy 2.4.0 (vagy újabb)
- Pandas 2.3.3 (vagy újabb)
- Customtkinter 5.2.2 (vagy újabb)
- Pillow 12.1.1 (vagy újabb)
- Openpyxl 3.1.5 (vagy újabb)

Ezek meglétét az alkalmazás a futtatás elején ellenőrzi, azonban, ha valamelyiket nem találja, felajánlja azok együttes telepítését. Tűzfal esetén engedélyezni kell az alkalmazást.



A telepítés egy parancssoros ablakban, az *Igen* gombra kattintás után automatikusan történik. A parancssoros ablak bezárása után az alkalmazás telepítése sikeresen megtörtént.

Ha az alkalmazás valamiért mégsem tudja a bővítményeket telepíteni (pl. nincs rendszergazda jogosultsága a felhasználónak), vagy a csomagok sérültek, akkor azokat manuálisan kell telepíteni (frissíteni). A Parancssor (“*cmd.exe*”) megnyitása után írjuk be az alábbi parancsokat egymás után:

```
pip install numpy --upgrade
pip install pandas --upgrade
pip install customtkinter --upgrade
pip install pillow --upgrade
pip install openpyxl --upgrade
```

Irányítószám adatbázis betöltése:

Az alkalmazás a települések beazonosításához – a lehetséges elgépelések miatt – a cím mezők helyett az irányítószámot használja kulcsmezőként. Az irányítószámokhoz tartozó megfelelő településnevet külső adatbázisokból társítja.

A Magyar Posta irányítószámokat tartalmazó adatbázisa és a Központi Statisztikai Hivatal helységnévtára nem teljesen konzisztens, ezért ezeket a program elindításkor automatikusan egyesíti (*futásidő ~5mp*).

- Posta, 2026.01.20-i állapot: `lib\Irányitoszam-Internet_uj.xlsx`
 - Forrás: https://www.posta.hu/static/internet/download/Irányitoszam-Internet_uj.xlsx
- KSH, 2025.01.01-i állapot: `lib\hnt_letoltes_2025.xlsx`
 - Forrás: https://www.ksh.hu/docs/helysegnevtar/hnt_letoltes_2025.xlsx

Megjegyzés: A fenti adatbázisok frissíthetők, a *lib* könyvtárban a fájlok cseréjével és a fenti fájlnevek megtartásával.

Az alkalmazás a közigazgatásilag nem önálló településrészeket a helység hivatalos megnevezésével helyettesíti, pl. “Gyöngyös - Mátrafüred” = “Gyöngyös”.

Használathoz szükséges adatstruktúra:

A könnyebb azonosítás érdekében a továbbiakban a vállalatok telephelyadatait tartalmazó adatbázist *branches* fájlnek, a székhelyadatait tartalmazó adatbázist *companies*-nak nevezzük. Az elnevezések a projekthez átadott adatfájlokból származnak:

branches_2025_anonym.xlsx (SHA1: A2F57C06BA0C6A213A1DEA07287C9538B55FB8EB)
branches_anonym.csv (SHA1: 42D7C08E34659429611B67ED4A71395843491C93)
companies_anonym.csv (SHA1: D015468B090CC90E9678EA120E0A5F5773CC98DC)

A szoftver a *branches* fájlok bemeneteire olyan telephelyadatokat tartalmazó adatbázist vár mely oszlopstruktúrája a következő:

'Crefo szám', 'Cím típus kód', 'Cím típus', 'Ország kód', 'Ország', 'Írányítószám', 'Település', 'Utca',
'Házszám'

A *companies* fájl esetében a következő struktúra szükséges:

'Crefo szám', 'TEÁOR megnevezés', 'Írányítószám', 'Település', 'Cím', 'Jogi forma', 'KKV', 'Megye', 'Járás',
'Alapítás éve', 'Jogi státusz', 'Utolsó mérleg dátuma', 'Active From', 'Active Until'

A szoftver mindkét esetben dinamikusan kezeli az .xlsx és a .csv kiterjesztéseket.

Megjegyzés: A szoftver a bemeneti fájlokban lévő *Település* mezőt a megállapodás alapján nem használja, mivel azok sok esetben elírást tartalmazhatnak. A címek összeállításához szükséges települést az irányítószám alapján határozzuk meg, azonban Magyarországon egy irányítószám alá több település is tartozhat. Az adatbázismotorok ilyen esetben az adott irányítószámhoz tartozó összes települést alárendelik, ami kezelés nélkül duplikációkhoz vezet. Ezt elkerülendő, a szoftver az egyazon irányítószámok alá tartozó települések közül nem véletlenszerűen választ egyet, hanem a településeket jogállás szerint rangsorolja, így irányítószám-egyezés esetén a magasabb “rangút”, például város és község esetén a várost választja. Pl. Kistarcsa irányítószáma 2143, azonban a szomszédos Csömörön is van 2143-as irányítószámú utca, így azt Kistarcsához rendeli. Azonos irányítószám és jogállás esetén a településnevek ábécé sorrendjéből az elsőt választja.


Használat:



A Power BI kimutatáshoz szükséges adatfájl két módon is elkészíthető:


1) Egy *branches* fájl és a *companies* fájl egyesítése esetén elegendő egy-egy adatfájl elérési útvonalát megadni, vagy a *Megnyitás* gombbal kiválasztani.

2) Két *branches* fájl előkészítése és egyesítése akkor szükséges, ha több évnyi adatunk van, de az adatbázisok között lehetnek átfedések, duplikációk. Ilyenkor a szoftver a két fájlt együttesen dolgozza fel és az ismétlődő sorokat eltávolítja, így több évnyi adat összevonható. Ez esetben az erre szolgáló jelölődobozt aktiválni kell, majd meg kell adni a második *branches* fájl útvonalát is.



A jelölődoboz aktiválásakor felugrik egy figyelmeztető ablak, mely a fájlok időrendi sorrendjére figyelmeztet, mivel a program az *Első fájl útvonala* mezőt tartja idő szerint újabbnak.

A szükséges adatfájlok megadása után az *Indítás* gombbal a szoftver előbb átalakítja, majd összevonja a fájlokat.



A kimeneti (*output.csv*) fájl mentése a *Mentés* gombbal elvégezhető. Nagy adatfájlok esetében ez néhány percet igénybe vehet.